

AN INFORMATION-THEORETIC APPROACH TO THE ORGANIZATION OF MORPHOSYNTACTIC INFORMATION UNDER FORMAL CONSTRAINT

Leonardo Tornabene — luglio 2026

SOMMARIO

Un vincolo formale può essere descritto, entro un'appropriata rappresentazione, come una restrizione imposta all'insieme delle sequenze linguistiche possibili; tale restrizione determina un condizionamento della distribuzione delle scelte linguistiche effettivamente realizzate. Questo progetto mira a verificare se la distinzione qualitativa fra prosa e poesia esametrica (sottoposta a un vincolo formale nella composizione metrica) lasci una firma misurabile nell'organizzazione predittiva delle sequenze morfosintattiche. Universal Dependencies costituisce il riferimento per la mappatura morfosintattica: il framework di Universal Dependencies utilizza infatti categorie morfologiche e relazioni di dipendenza sintattica per descrivere la struttura linguistica. Il progetto non analizza direttamente i treebank di UD, bensì una loro proiezione lineare e ridotta, che conserva per ciascuna parola la categoria grammaticale e il tipo di relazione di dipendenza che la lega alla parola da cui grammaticalmente dipende (il suo *head*). Queste sequenze saranno analizzate utilizzando un unico strumento statistico: il *context tree* elaborato dal teorico dell'informazione Jorma J. Rissanen. Si tratta di un modello a contesti di lunghezza variabile, costruito secondo il principio della Minimum Description Length: una maggiore complessità del modello è accettata soltanto se riduce la lunghezza complessiva della descrizione dei dati. Questo modello predittivo consente di tenere in considerazione la complessità della lingua elaborando però un'analisi statistica rigorosa su come la conoscenza del passato influenzi quella del futuro nei due diversi regimi testuali, prosaico e poetico. La radice del modello (la distribuzione dei simboli senza alcun contesto), il guadagno ottenuto dal contesto (quanti bit per simbolo si risparmiano conoscendo il passato recente della sequenza) e il trasferimento predittivo fra regimi (quanto le regolarità apprese in un regime predicono i documenti dell'altro) forniscono tre letture coordinate (distribuzionale, sequenziale e predittiva) dello stesso oggetto.

1. INTRODUZIONE

1.1 Problema generale. Già in *A Mathematical Theory of Communication* [1] Shannon osserva che le lingue naturali possono essere trattate, per specifici problemi quantitativi, come processi che producono sequenze discrete di simboli scelti da un insieme finito. Questa idealizzazione non equivale a una teoria generale del linguaggio: rende però possibile formulare domande precise sulla distribuzione, sulla prevedibilità e sulla dipendenza contestuale degli elementi osservati. Entro tale approssimazione, un vincolo formale può essere considerato come una restrizione che agisce sul processo di produzione della sequenza. La metrica poetica ne costituisce un caso particolarmente netto, perché impone condizioni sistematiche alla realizzazione del testo pur lasciando disponibile un ampio insieme di alternative linguisticamente ammissibili.

1.2 Domanda di ricerca. La distinzione fra prosa e poesia è qualitativamente riconoscibile sul piano letterario, metrico e percettivo. Il progetto chiede se tale distinzione lasci anche una firma quantitativa nell'organizzazione morfosintattica dei testi. La domanda non è se un classificatore riesca a separare prosa e verso, né se la poesia presenti genericamente maggiore o minore entropia. La domanda è più specifica: rappresentati i testi allo stesso livello morfosintattico e applicato uniformemente lo stesso modello predittivo, in quale sede dell'organizzazione statistica emerge l'eventuale differenza fra regime

esametrico e regime prosastico? Rispettivamente nella frequenza dei simboli, nel valore informativo del contesto lineare o nella trasferibilità delle regolarità predittive fra i due regimi?

1.3 Livello di analisi. Il livello scelto è morfosintattico, non semantico e non direttamente prosodico. La scelta risponde a un'esigenza di controllo: lemmi e parole incorporano contenuto, tema, genere e tradizione lessicale; le sequenze prosodiche descrivono direttamente il metro, ma non consentono di stabilire se il vincolo si accompagna a una riorganizzazione della realizzazione grammaticale. Le categorie UPOS e le relazioni DEPREL di Universal Dependencies [2] permettono invece di astrarre, in misura controllata, dal contenuto lessicale mantenendo informazione sulla classe grammaticale delle parole e sulla funzione che esse svolgono nella struttura di dipendenza.

1.4 Ipotesi di collegamento. Il progetto non assume che il metro modifichi la grammatica del greco o del latino. Assume una tesi più limitata: un vincolo metrico forte può influire sulla selezione e sulla disposizione delle alternative che la grammatica rende disponibili. Ordine delle parole, scelta fra costruzioni concorrenti, impiego di particelle, distribuzione delle categorie, forme perifrastiche e soluzioni morfologiche possono concorrere alla soddisfazione del verso. Qualora tali adattamenti siano sistematici, una parte della loro traccia può essere conservata nella successione lineare delle categorie UPOS e delle relazioni DEPREL. Questa è l'ipotesi ponte che autorizza l'analisi statistica; non implica che ogni differenza osservata sia causata dal metro, né che la rappresentazione scelta catturi l'intera struttura linguistica.

1.5 Formulazione operativa. I testi vengono trasformati in sequenze di simboli morfosintattici e analizzati con un'unica famiglia di modelli predittivi a memoria variabile: un context tree con selezione MDL (Minimum Description Length), nella tradizione di Rissanen e nella formulazione operativa studiata da Schürmann e Grassberger [4, 8]. Lo strumento viene letto a tre livelli: la radice, che descrive il repertorio e la frequenza dei simboli; il guadagno di contesto, che misura quanti bit per simbolo il passato lineare consente di risparmiare rispetto alla radice; il trasferimento inter-regime, che misura quanto le regolarità apprese su un regime predicono documenti dello stesso o dell'altro regime. Il greco costituisce il contrasto primario; il latino fornisce una replica subordinata.

2. STATO DELL'ARTE

2.1 Analisi informazionale dei testi. L'applicazione della teoria dell'informazione alle lingue naturali risale allo stesso Shannon [1], ma la stima dell'entropia di sequenze linguistiche finite presenta difficoltà specifiche. I testi manifestano dipendenze a più scale e un numero di configurazioni che cresce rapidamente con la lunghezza del contesto. Gli stimatori basati sul conteggio diretto di blocchi a ordine fisso convergono quindi lentamente e possono diventare instabili. Schürmann e Grassberger [4] affrontano esplicitamente il problema attraverso stimatori legati alle lunghezze di codice prodotte da algoritmi di compressione, fra cui il metodo dei contesti di Rissanen. Montemurro e Zanette [5] impiegano invece stimatori di tipo Lempel–Ziv per misurare il contributo dell'ordine delle parole in più famiglie linguistiche.

2.2 Studi quantitativi del verso. La poesia è già stata oggetto di analisi informazionale, soprattutto sul piano prosodico. Mansilla e Bush [6] trasformano l'esametro greco e latino in serie simboliche ritmiche e utilizzano l'informazione mutua per descrivere differenze nella complessità dei pattern. Šeĭa e Gronas [7] propongono l'entropia degli intervalli fra accenti come misura continua della regolarità ritmica. Questi lavori mostrano che un vincolo metrico può essere trattato quantitativamente, ma operano su alfabeti prosodici. Il presente progetto sposta l'osservazione sul livello morfosintattico: non misura il metro in quanto tale, bensì verifica se la sua presenza si accompagna a differenze nell'organizzazione delle forme grammaticali attestate.

2.3 Universal Dependencies come riferimento descrittivo. Universal Dependencies è al tempo stesso un'infrastruttura di annotazione e un quadro coerente per la descrizione morfosintattica comparabile fra lingue [2]. Il modello assume le parole come unità fondamentali, le collega mediante relazioni binarie asimmetriche fra head e dipendente e tipizza tali relazioni attraverso etichette grammaticali. Gli alberi di base rappresentano una struttura morfosintattica di superficie centrata su predicati, argomenti e modificatori. UPOS descrive la categoria grammaticale della parola; DEPREL descrive la relazione del token con il proprio head. Il progetto adotta questo livello non perché Universal Dependencies costituisca una teoria esaustiva della sintassi, ma perché offre una rappresentazione esplicita, documentata, replicabile e sufficientemente uniforme per il confronto fra greco e latino.

2.4 Dalla struttura all'osservazione statistica. Le probabilità e le misure informative non sono indipendenti dalla rappresentazione su cui vengono calcolate. Greco et al. [21] sottolineano, in un contesto diverso e con finalità psicolinguistiche, che una misura statistica come il surprisal acquista contenuto linguistico soltanto rispetto al modello che definisce gli eventi e le probabilità. Il principio metodologico è rilevante anche qui: non basta applicare un algoritmo a simboli arbitrari; occorre specificare quale informazione linguistica quei simboli conservano. Nel presente progetto la coppia UPOS+DEPREL non coincide con l'albero sintattico completo. È una proiezione lineare e con perdita, derivata da una rappresentazione gerarchica: conserva la classe grammaticale e il tipo di dipendenza, ma non conserva l'identità dell'head, la distanza della dipendenza, la ramificazione, l'embedding o l'intera topologia dell'albero. Le conclusioni saranno perciò riferite all'organizzazione predittiva di questa rappresentazione, non alla grammatica nel suo complesso.

2.5 Modelli a contesti di lunghezza variabile. L'algoritmo dei contesti nasce con Rissanen [8]. Il quadro statistico delle variable-length Markov chains è sviluppato da Bühlmann e Wyner [9], mentre Csizsár e Talata [10] stabiliscono risultati di consistenza per la stima degli alberi di contesto mediante criteri di selezione del modello quali BIC e MDL. Il precedente linguistico più vicino è Galves et al. [11], che utilizzano la selezione di context tree per recuperare il ritmo linguistico da testi scritti e distinguere portoghese europeo e brasiliano. Il loro alfabeto è ritmico-accentuale e la domanda riguarda la varietà linguistica; il presente progetto usa un alfabeto morfosintattico, assume come fattore di contrasto un vincolo metrico e introduce come lettura centrale il trasferimento predittivo fra regimi. Il Context-Tree Weighting [12], che media sui modelli anziché selezionarne uno, costituisce un possibile comparatore di robustezza.

2.6 Posizionamento nelle lingue classiche. I dati derivano dall'Ancient Greek and Latin Dependency Treebank del progetto Perseus [13], convertito nello standard Universal Dependencies. Chen et al. [14] mostrano che la distinzione fra prosa e verso latino è facilmente classificabile mediante tratti arricchiti di part-of-speech. La semplice discriminabilità dei due regimi non costituisce quindi un contributo sufficiente. Il problema qui proposto è localizzare la differenza all'interno di uno strumento predittivo: stabilire se essa sia prevalentemente distribuzionale, se riguardi il valore del contesto o se si manifesti come struttura specifica di regime che trasferisce peggio fra prosa ed esametro. Herrera et al. [15] mostrano inoltre l'utilità e i limiti delle descrizioni contrastive estratte da treebank UD, richiamando l'esigenza di controllare le convenzioni annotative.

2.7 Limite teorico del modello statistico. Il context tree non è proposto come modello della grammatica delle lingue naturali. L'argomento classico di Chomsky [16] contro l'adeguatezza dei modelli markoviani a memoria finita come descrizioni grammaticali conserva piena validità. La giustificazione del context tree è strumentale: esso fornisce una procedura adattiva e riproducibile per misurare la prevedibilità sequenziale di una rappresentazione discreta, confrontando tutti i regimi entro la stessa classe di modelli. Non vengono formulate affermazioni sulla competenza linguistica, sulla grammaticalità o sulla natura generativa del linguaggio. La teoria linguistica interviene esclusivamente per definire e delimitare il livello osservato.

2.8 Inquadramento concettuale. Il richiamo alla prospettiva dei sistemi complessi ha carattere epistemologico. Anderson [3] osserva che differenze quantitative di organizzazione possono accompagnarsi a distinzioni qualitative a livelli descrittivi superiori. Prosa e poesia vengono quindi trattate come regimi differenti di organizzazione della stessa materia linguistica, uno dei quali è sottoposto a un vincolo formale forte. Il progetto non interpreta lo scarto come transizione di fase o rottura di simmetria in senso fisico: nessuna quantità del disegno operationalizza tali nozioni.

3. IPOTESI DI RICERCA

3.1 Ipotesi generale. L'ipotesi di ricerca è che il vincolo metrico si accompagni a una riorganizzazione statisticamente rilevabile della distribuzione delle realizzazioni morfosintattiche entro lo spazio delle alternative ammesse dalla grammatica, e che tale riorganizzazione lasci una firma nell'organizzazione predittiva della sequenza UPOS+DEPREL. Non viene assunta una direzione generale dell'effetto: maggiore vincolo non significa necessariamente minore entropia, maggiore regolarità o maggiore prevedibilità. La direzione è specificata soltanto quando deriva dalla definizione della statistica e dall'ipotesi di struttura specifica di regime.

3.2 Premessa distribuzionale. Prima delle ipotesi, i due regimi vengono confrontati al livello più elementare: il repertorio dei simboli UPOS+DEPREL e le loro frequenze relative, senza utilizzare alcun contesto; nel *context tree* questo repertorio corrisponde alla radice. Questo confronto ha la funzione di preparare la lettura delle ipotesi che seguono. Se i due regimi impiegano le stesse categorie con frequenze simili, un'eventuale differenza nelle ipotesi successive riguarderà il modo in cui le categorie vengono organizzate in sequenza, e non l'inventario disponibile, coerentemente con l'ipotesi di collegamento (Introduzione 1.4); repertori marcatamente diversi imporrebbero invece maggiore cautela nell'interpretazione. Per dare a questo confronto una misura riassuntiva, la distanza fra le distribuzioni di radice dei due regimi viene quantificata dalla divergenza di Jensen–Shannon [22] (Metodologia 6.8).

3.3 Ipotesi H1: lettura sequenziale. Il valore predittivo del contesto lineare differisce fra i due regimi. La statistica confermativa confronta la media per documento del guadagno di contesto, cioè i bit per simbolo risparmiati dal modello completo rispetto alla sola radice. Questa statistica sarà calcolata held-out, cioè su testo mai utilizzato per l'addestramento del modello (Metodologia 6.6). I punteggi vengono ottenuti mediante modelli leave-one-document-out: ciascuno addestrato su tutti i documenti tranne quello in esame e costruito senza consultare le etichette di regime e ad una taglia di addestramento comune, così che i punteggi siano proprietà fisse dei documenti. Ciò garantisce la possibilità di effettuare un test di permutazione.

3.4 Ipotesi H2: lettura predittiva. Le regolarità apprese all'interno di un regime predicono meglio documenti dello stesso regime che documenti dell'altro. La statistica confermativa è l'asimmetria di trasferimento: per ogni documento si sottrae alla cross-entropia ottenuta con il modello addestrato sull'altro regime la cross-entropia ottenuta con il modello addestrato sul proprio regime, a parità di quantità di dati di addestramento. Un valore medio positivo indica la presenza di una struttura predittiva specifica di regime. Una lettura secondaria ma possibile è la profondità media del contesto selezionato, che è tuttavia maggiormente sensibile ai parametri dello strumento.

3.5 Ipotesi H3: replica latina. I segni degli effetti principali individuati nel greco si replicano qualitativamente nel latino, con i relativi intervalli di confidenza e con le grandezze calcolate rispetto a sottocampioni greci della stessa taglia, nei limiti imposti dalla dimensione e dalla composizione del corpus. La replica latina è subordinata per costruzione: non entra nella famiglia di test confermativi e non è interpretata come confronto simmetrico fra lingue.

3.6 Famiglia confermativa. La famiglia di test confermativi comprende soltanto le misure afferenti alle ipotesi H1 e H2. La molteplicità dei test è controllata mediante la procedura di Holm–Bonferroni [17],

che adegua le soglie di significatività alla valutazione congiunta di più ipotesi, con $\alpha = 0,05$. Questa famiglia ristretta consolida una formulazione precedente del progetto, che affiancava più misure classiche indipendenti; il consolidamento su un unico strumento e la definizione delle statistiche confermatrice sono anteriori a qualunque calcolo sui dati reali, così che nessuna scelta inferenziale risulti orientata dall'esplorazione preliminare dei dati.

4. RAZIONALE DEL CASO DI STUDIO

4.1 Perché il livello morfosintattico. Il livello morfosintattico costituisce un compromesso controllato fra prossimità alla struttura linguistica e comparabilità statistica. Un'analisi lessicale sarebbe fortemente esposta a tema, autore, genere e tradizione formulare; un'analisi puramente metrica misurerebbe direttamente il vincolo già noto. UPOS e DEPREL consentono di osservare la distribuzione e la successione di categorie e funzioni grammaticali, riducendo l'incidenza dell'identità lessicale. Il progetto non considera questo livello come la rappresentazione completa della lingua, ma come un piano osservativo definito e replicabile sul quale formulare una domanda quantitativa precisa.

4.2 Perché Universal Dependencies. Universal Dependencies è scelto per tre ragioni. In primo luogo rende esplicita la struttura morfosintattica di superficie attraverso parole, head e dipendenze tipizzate. In secondo luogo applica uno schema condiviso a lingue differenti, permettendo di utilizzare la medesima funzione di codifica nel greco e nel latino senza costruire una mappatura ad hoc fra due sistemi annotativi. In terzo luogo i treebank Perseus forniscono testi in lingua originale, già segmentati e annotati, appartenenti sia alla poesia sia alla prosa. Lo schema comune non implica che gli alfabeti empiricamente realizzati nelle due lingue siano identici, né che ogni etichetta abbia perfetta equivalenza funzionale: tali asimmetrie vengono trattate come limiti e controllate mediante audit.

4.3 Perché prosa e poesia. Il confronto muove da una distinzione culturalmente e filologicamente consolidata, ma non assume che tale categoria coincida automaticamente con una separazione statistica. La distinzione viene sottoposta a verifica. La prosa classica è utilizzata come regime meno direttamente vincolato dalla struttura metrica; l'esametro come regime sottoposto a un vincolo quantitativo forte. Le differenze rilevate rimangono associazioni di corpus e non vengono attribuite causalmente al metro senza ulteriori controlli.

4.4 Perché l'esametro greco e latino. L'esametro costituisce una forma metrico-quantitativa riconoscibile e storicamente continua, pur con realizzazioni linguistiche, cronologiche e autoriali differenti [6]. La sua presenza in entrambe le tradizioni consente di verificare il metodo su due lingue flessive comparabili per storia e struttura, ma non identiche. Il greco offre un corpus sufficientemente esteso per il contrasto primario; il latino consente una replica prudente. La cosiddetta prosa coeva è operazionalizzata come prosa classica: una coevità stretta con l'epica arcaica non è disponibile e questa impossibilità costituisce un confondente esplicito.

4.5 Portata dell'ipotesi ponte. L'ipotesi ponte non richiede una teoria specifica dell'interfaccia fra metro e sintassi. È sufficiente che il vincolo metrico ridistribuisca, anche indirettamente, la probabilità di soluzioni linguistiche già ammesse: posizioni relative, categorie, relazioni e sequenze di funzioni. Il progetto misura l'esito aggregato di tali scelte nella rappresentazione osservata. Non tenta di derivare le costruzioni dal metro, di identificare una grammatica poetica autonoma o di spiegare la competenza dei parlanti.

5. CORPUS E STRUMENTI INFORMATICI

5.1 Struttura dei dati. I dati sono i treebank UD_Ancient_Greek-Perseus e UD_Latin-Perseus, release v2.18 [18, 19], conversioni nello standard Universal Dependencies dell'Ancient Greek and Latin

Dependency Treebank [13]. Ogni frase è rappresentata nel formato CoNLL-U. Per ciascuna parola sintattica sono disponibili, fra gli altri campi, forma, lemma, categoria UPOS, tratti morfologici, indice dell'head e relazione DEPREL. Il progetto utilizza UPOS e la relazione di dipendenza di base; le altre informazioni sono mantenute per audit e tracciabilità, ma non entrano nell'alfabeto primario.

5.2 Modello di osservazione. Sia T una frase annotata come albero di dipendenza e siano $v_1, \dots, v_n$ le sue parole nell'ordine superficiale. A ciascuna parola ritenuta viene associato il simbolo

$$\varphi(v_i) = \text{UPOS}(v_i):\text{DEPREL-base}(v_i).$$

La sequenza osservata è quindi

$$\varphi(T) = [\varphi(v_1), \dots, \varphi(v_n)].$$

Questa funzione conserva l'ordine lineare, la categoria grammaticale e il tipo della relazione del token con il proprio head. Non conserva l'identità dell'head, la direzione e la lunghezza della dipendenza, la ramificazione, le relazioni fra dipendenze o la struttura di costituenza. La sequenza è perciò definita come rappresentazione lineare, coarse-grained e dependency-informed della realizzazione morfosintattica. È questo l'oggetto del modello statistico.

5.3 Corpus greco. Il treebank greco comprende 13.919 frasi e 202.989 token [18]. Il contrasto primario oppone cinque documenti esametrici — Iliade, Teogonia, Opere e giorni, Scudo di Eracle, Inno a Demetra — a sei documenti di prosa classica — Erodoto, Tucide e quattro orazioni di Lisia. Il corpus comprende inoltre dodici tragedie, sette di Eschilo e cinque di Sofocle, utilizzate come insieme esplorativo di verso non esametrico, e sei autori di prosa post-classica, utilizzati come controllo cronologico. Le categorie operative distinguono esametro, prosa classica, prosa post-classica, altro verso e documenti esclusi. Le assegnazioni vengono verificate mediante audit documentale prima dell'analisi.

5.4 Corpus latino. Il treebank latino comprende 2.273 frasi, 28.868 token e 29.223 parole sintattiche, con 355 multiword token, fra cui univernazioni clitiche come -que e -ue, che vengono espanse [19]. Il regime esametrico comprende Eneide e Metamorfosi. La prosa riunisce, per ragioni di numerosità, testi classici e post-classici; Properzio e Fedro costituiscono il verso non esametrico; la Vulgata è esclusa. Si tratta di un totale di 6 documenti in prosa e 2 in poesia; questa asimmetria, unita ai volumi ridotti del corpus e all'eterogeneità dei generi impongono un uso subordinato del latino.

5.5 Alfabeto primario. L'alfabeto conserva

12 UPOS: ADJ, ADP, ADV, AUX, CCONJ, DET, NOUN, NUM, PART, PRON, SCONJ, VERB

e 23 DEPREL: root, nsubj, csubj, obj, iobj, ccomp, xcomp, obl, advcl, advmod, acl, amod, appos, det, nummod, nmod, case, mark, aux, cop, cc, conj, parataxis.

I sottotipi delle relazioni vengono ricondotti alla relazione di base; PROPN viene ricondotto a NOUN nel latino, che distingue i nomi propri. Punteggiatura, X, interiezioni e simboli vengono esclusi. Le relazioni residuali seguono una politica controllata: eliminazione nell'analisi primaria e accorpamento in una categoria residuale unica nell'analisi di sensibilità. Se una relazione esclusa supera una soglia minima stabilita dei token grezzi di un regime, entrambe le politiche vengono riportate con pari rilievo. L'alfabeto teorico massimo è di 276 simboli; quello effettivo è l'insieme dei simboli osservati dopo l'audit.

5.6 Controllo solo-UPOS e confini. Tutte le statistiche principali vengono replicate su un alfabeto costituito dai soli UPOS. Questo controllo separa i risultati robusti alla sola categorizzazione grammaticale da quelli dipendenti dalle relazioni di dipendenza, la cui annotazione può essere più rumorosa nei testi poetici e nell'ordine non canonico [14, 15]. Nell'analisi primaria i contesti vengono azzerati all'inizio di ogni frase; un'analisi di sensibilità introduce un simbolo esplicito di confine. I confini di verso non sono codificati nei treebank e non vengono ricostruiti nel disegno primario.

5.7 Provenienza e licenza. La release dei treebank, i commit e gli hash dei file vengono registrati; i dati grezzi rimangono immutati. La licenza CC BY-NC-SA 2.5 consente l'uso di ricerca ma non la ridistribuzione indiscriminata dei dati; vengono pubblicati codice, configurazioni e risultati derivati.

6. METODOLOGIA

6.1 Sequenze e unità di analisi. Per ciascun documento le frasi vengono ordinate secondo il corpus e trasformate in sequenze di simboli; le eliminazioni chiudono le lacune e, nell'analisi primaria, i contesti non attraversano i confini di frase (la politica alternativa, con simbolo esplicito di confine, è parte del piano di sensibilità, Metodologia 6.12). L'unità di analisi scelta è il documento: non il token, non la frase, non una porzione arbitraria di testo. Blocchi di lunghezza comparabile possono essere impiegati esclusivamente per grafici descrittivi interni ai documenti; non costituiscono repliche statistiche indipendenti.

6.2 Lo strumento: il *context tree* a memoria variabile. Un *context tree* assegna al simbolo successivo una distribuzione di probabilità sull'alfabeto, condizionata a un suffisso del passato di lunghezza variabile [9]. Il modello viene costruito sui suffissi effettivamente osservati fino a una profondità massima decisa prima di ogni analisi confermativa (Metodologia 6.12). Per ciascun contesto s un predittore prequenziale calcola le probabilità prima di aggiornare i conteggi. Per impedire la stima banale che assegnerebbe probabilità nulla ad ogni simbolo non ancora incontrato si adotta uno smoothing bayesiano con $\beta = 0,5$, che corrisponde alla stima di Krichevsky–Trofimov discussa da Schürmann e Grassberger [4]. Per ogni contesto si confrontano la lunghezza di codice assegnata dal nodo e quella che il suo genitore avrebbe assegnato agli stessi eventi; il vantaggio del contesto è:

$$\Delta(s) = L_{\text{genitore}}(s) - L_{\text{proprio}}(s).$$

Il contesto più profondo viene selezionato soltanto se $\Delta(s) > 0$ e dispone di almeno $k_{\min} = 2$ osservazioni. Questa regola opera lungo l'intero percorso dei suffissi: un contesto può essere utilizzato soltanto se ogni suo prefisso intermedio soddisfa a sua volta entrambe le condizioni, e l'algoritmo si arresta al primo livello che non le soddisfa. Nessun contesto profondo viene così accettato in virtù di una fluttuazione isolata, se i livelli che vi conducono non giustificano ciascuno la propria complessità. La selezione segue il principio MDL (Minimum Description Length): una maggiore complessità è accettata solo quando riduce la lunghezza complessiva della descrizione, e la codifica prequenziale incorpora da sé il costo del modello, senza penalità additive separate. La corrispondenza fra l'implementazione concreta e la formulazione di Schürmann e Grassberger [4] viene validata esplicitamente prima di ogni analisi (Metodologia 6.12).

6.3 La quantità misurata: lunghezze di codice e cross-entropia. Il modello non viene interpretato come sorgente reale della lingua: le lunghezze di codice sono quantità operative, prodotte da una classe di predittori applicata uniformemente a tutti i regimi. Il confronto fra un documento e un modello predittivo si esprime con la cross-entropia held-out: per un documento d e un modello M congelato,

$$CE(d | M) = -\frac{1}{N_d} \sum_t \log q_M(x_t | c_t),$$

dove q_M è la probabilità che M assegna al simbolo osservato in posizione t dato il contesto disponibile c_t , e N_d è il numero di posizioni valutate; il logaritmo è in base 2 e l'unità è il bit per simbolo [20]. Ogni valutazione avviene ad albero congelato, su materiale che il modello non ha visto in addestramento. Quando il passato osservato non corrisponde ad alcun contesto dell'albero congelato, la valutazione ricorre al più profondo contesto disponibile lungo il percorso dei suffissi e, in ultima istanza, alla radice, che è sempre definita; il lisciamiento bayesiano garantisce inoltre che nessun simbolo riceva probabilità nulla, neppure quando non è mai stato osservato in addestramento. Ogni posizione ammette quindi una lunghezza di codice finita e ben definita. È importante notare che il confronto non richiede che M sia

una descrizione adeguata della grammatica reale: richiede che lo stesso strumento sia validato e applicato con le medesime regole a tutti i documenti.

6.4 Perché un unico strumento. Le misure classiche di ordine fisso sono già contenute nel modello, con le loro limitazioni attenuate: la radice induce una distribuzione di ordine zero, dalla quale un'entropia di Shannon può essere derivata come diagnostica interna. I nodi di profondità 1 invece possono essere ricondotti a distribuzioni condizionate di ordine 1, da cui una lettura dell'entropia condizionata. Infine il confronto fra radice e contesti quantifica direttamente il guadagno sequenziale (Metodologia 6.7). Va tuttavia mantenuta una distinzione: l'entropia di una distribuzione stimata, la cross-entropia calcolata su materiale mai visto in addestramento e la lunghezza di codice prequenziale sono quantità differenti, e ciò che il progetto misura e confronta sono soltanto la seconda e la terza (Metodologia 6.3). Calcolare separatamente entropia, entropia condizionata e informazione mutua come risultati indipendenti aumenterebbe la molteplicità, senza affrontare la rigidità e la sparsità proprie di queste stesse stime ad ordine fisso, che il modello a contesti variabili consente invece di attenuare. L'obiezione concettuale ai modelli a memoria finita come descrizioni della grammatica (Chomsky [16]) resta invece intatta, nei termini esposti in 2.7 e ripresi in 8.5.

6.5 Perché non confrontare gli alberi. Il *context tree* è impiegato come strumento di misura, non come oggetto di studio: ciò che viene confrontato non sono i modelli, ma le lunghezze di codice che una medesima procedura, applicata con le stesse regole a tutti i documenti, assegna a dati mai visti in addestramento. L'opzione apparentemente più diretta sarebbe adattare un albero a ciascun documento e confrontare le strutture selezionate (quali contesti, a quale profondità). Essa è tuttavia da evitare per tre ragioni convergenti.

La prima è che la struttura di un albero selezionato con MDL dipende dalla quantità di dati prima ancora che dall'organizzazione della sorgente: un nodo viene accettato solo quando i suoi conteggi ne giustificano la complessità, e con poco testo pochi contesti raggiungerebbero il supporto necessario. Due documenti analizzati con lo stesso processo, ma di taglia molto diversa, produrrebbero alberi sistematicamente diversi per costruzione, e il confronto fra strutture misurerebbe soprattutto la lunghezza dei testi; i risultati di consistenza per la selezione degli alberi di contesto [10] sono asintotici, e le taglie documentali qui in gioco ne sono lontane.

La seconda è che la corrispondenza fra alberi e distribuzioni predittive è molti-a-uno: alberi strutturalmente diversi possono codificare predizioni quasi identiche, e una fluttuazione minima nei conteggi può ribaltare la selezione di un nodo il cui vantaggio è prossimo alla soglia. Le lunghezze di codice sono il dato stabile, l'identità dei nodi selezionati ne costituisce una controparte fragile. Il modello MDL considera il costo di descrizione dei dati, non il particolare modello che lo realizza.

La terza ragione è inferenziale: un confronto fra strutture richiederebbe di quantificare una distanza fra alberi: una simile misura risulta difficilmente definibile e non rappresenta una quantità scambiabile su cui fondare un test esatto; le cross-entropie sono invece scalari in bit per simbolo, con la struttura di scambiabilità descritta nel paragrafo che segue.

6.6 La strategia a modello comune e la scambiabilità. Per superare queste criticità il progetto adotta una strategia a modello comune. Per ciascun documento si costruisce un modello utilizzando tutti gli altri: lo stesso strumento (stesso alfabeto, stessa profondità massima, stesso liscio, stessa regola di selezione) viene ricostruito di volta in volta con il materiale disponibile, escludendo il documento in esame. Il modello così ottenuto viene congelato e chiamato a predire proprio il documento escluso: la valutazione è quindi autenticamente held-out, cioè su dati che il modello non ha mai visto. La ragione è l'onestà della misura: un modello valutato sul proprio materiale di addestramento non rivela quanto un testo sia prevedibile, ma quanto lo abbia memorizzato, e premierebbe sistematicamente i documenti più lunghi e ripetitivi; chiedere al modello di predire simboli mai visti consente una reale quantificazione operativa di "quanto aiuta il contesto".

Per il guadagno di contesto lo strumento è addestrato sull'insieme indistinto degli altri documenti, poesia e prosa insieme, senza mai consultare le etichette di regime. Il modello comune funge così da metro: codifica le regolarità sequenziali del corpus, e ciascun documento viene interrogato rispetto a quella media. Poiché i documenti hanno lunghezze molto diverse, escludere un poema sottrarrebbe all'addestramento assai più materiale che escludere un'orazione, e il punteggio finirebbe per riflettere anche la quantità di dati rimasta, non soltanto il documento valutato. Per neutralizzare questo effetto, ogni insieme di addestramento viene riportato ad una medesima taglia comune T , campionando frasi intere in modo uniforme e senza consultare le etichette, e ripetendo l'estrazione su più semi con media dei punteggi. T è definita come la minima quantità di materiale disponibile fra tutte le condizioni di addestramento dei due protocolli, sequenziale e predittivo (Metodologia 6.7 e 6.8). La parità di taglia elimina la quantità di materiale di addestramento come possibile fonte sistematica devianza nei risultati. Inoltre la cecità alle etichette garantisce la validità del test di permutazione, per la ragione che segue.

Un test statistico non verifica direttamente l'ipotesi di ricerca: misura quanto i dati osservati sarebbero sorprendenti se non esistesse alcuna differenza fra i regimi. Occorre dunque saper rappresentare esattamente questo scenario nullo. Se i regimi non differiscono, le etichette “esametro” e “prosa” sono contingenti: i punteggi dei documenti sarebbero quelli che sono per ragioni estranee al regime, e qualunque riassegnazione delle etichette sarebbe plausibile quanto quella reale; è ciò che si intende dicendo che, sotto l'ipotesi nulla, le etichette sono scambiabili. Il test di permutazione considera allora tutte le 462 ricombinazioni possibili degli undici documenti in cinque e sei (cinque per la poesia, sei per la prosa), calcola per ciascuna la differenza fra le medie dei due gruppi e colloca il valore realmente osservato dentro questa distribuzione. Il p -value che ne risulta è esatto, senza approssimazioni asintotiche né assunzioni distributive: un requisito indispensabile con soli undici documenti, dove nessun test parametrico sarebbe difendibile. L'enumerazione ha però senso a una sola condizione: che i punteggi siano proprietà fisse dei documenti, calcolati una volta e validi sotto ogni riassegnazione. È esattamente ciò che la costruzione cieca garantisce. Se invece i punteggi fossero prodotti da modelli specifici di regime (i poemi misurati da un modello di poesia, le prose da un modello di prosa), ogni punteggio porterebbe l'impronta dell'etichetta ricevuta per il modo stesso in cui è stato calcolato, prima e indipendentemente da qualunque differenza reale; permutare le etichette tenendo fissi i punteggi non rappresenterebbe più lo scenario nullo, e il numero ottenuto avrebbe la forma di un p -value senza averne il significato. La costruzione cieca garantisce che i punteggi siano invarianti rispetto ad ogni successiva riassegnazione delle etichette, e possano perciò essere soggetti a permutazione. L'esattezza del test resta però condizionata ad un'ulteriore assunzione, che la costruzione non può fornire da sola: che sotto l'ipotesi nulla gli undici documenti siano effettivamente scambiabili fra i due gruppi. Il corpus contiene più opere dello stesso autore e forti simmetrie fra regime, autore, epoca e genere; per questo l'analisi primaria è affiancata da una replica conservativa a livello di autore (Metodologia 6.11), che tratta come unità i blocchi autoriali anziché i singoli documenti.

Nel trasferimento predittivo (che chiede se nessun regime possiede struttura propria) i due modelli addestrati sulla stessa quantità di materiale dovrebbero essere intercambiabili per ciascun documento, e il segno della differenza risulterebbe arbitrario. Pertanto la più semplice formulazione di un test statistico sui risultati sarebbe il sign-flip (Metodologia 6.11). L'inversione simultanea e indipendente dei segni su tutti i documenti richiede però la simmetria congiunta dei segni sotto l'ipotesi nulla, che non discende automaticamente dalla costruzione, perché i modelli che producono i punteggi condividono parte del materiale di addestramento. Questa assunzione deve essere formulata esplicitamente, e la sua adeguatezza è sottoposta alla supervisione statistica (Il Ruolo del Supervisore 11.1).

In entrambi i casi la logica del disegno è la stessa: costruire le misure in modo che le proprietà richieste dai test siano, per quanto possibile, garantite dalla costruzione, dichiarando esplicitamente come assunzione ciò che la costruzione non può garantire.

6.7 H1 guadagno di contesto (lettura sequenziale). Per ogni documento d viene adattato un modello sull'insieme degli altri documenti (alla taglia comune T), secondo il protocollo cieco alle etichette esposto in Metodologia 6.6. Sul documento escluso si calcolano la cross-entropia della sola radice e quella del modello completo; il guadagno medio è

$$G(d) = CE_{radice}(d) - CE_{completo}(d),$$

in bit per simbolo: misura quanto la conoscenza del passato recente riduce il costo di codifica rispetto alla sola distribuzione marginale dei simboli. Un valore positivo rappresenta un risparmio di codice dovuto al contesto; un valore negativo indica che, sul documento tenuto fuori dall'addestramento, la struttura contestuale appresa dagli altri documenti non migliora la predizione rispetto alla sola radice.

Per evitare che differenze editoriali nella segmentazione delle frasi influenzino la quantità di contesto disponibile, $G(d)$ viene calcolato primariamente soltanto sulle posizioni precedute, all'interno della stessa frase, da un numero minimo di simboli; la rimozione di questa restrizione è una variazione del piano di sensibilità (Metodologia 6.12). La statistica confermativa è la differenza fra la media di $G(d)$ nei documenti esametrici e la media nei documenti di prosa classica. Poiché il vettore dei punteggi è costruito senza utilizzare le etichette, esso rimane invariato sotto la loro riassegnazione. Il test di permutazione è quindi applicabile al vettore dei punteggi, a condizione di accettare l'assunzione di scambiabilità dei documenti sotto l'ipotesi nulla (Metodologia 6.6): le 462 assegnazioni possibili degli undici documenti nei due gruppi.

6.8 Distribuzioni di radice. Poiché il guadagno è definito come risparmio rispetto alla radice, le distribuzioni dei simboli nei due regimi saranno inoltre ispezionate come controllo interpretativo (Ipotesi di Ricerca 3.2): repertori simili accompagnati da guadagni sistematicamente diversi indicano una differenza nell'organizzazione sequenziale, non nell'inventario delle categorie impiegate, coerentemente con l'ipotesi ponte per cui il vincolo metrico polarizza la selezione fra alternative grammaticalmente disponibili (Introduzione 1.4, Razionale del Caso di Studio 4.5). Il confronto è riassunto da una misura sintetica: la divergenza di Jensen–Shannon [22] fra le distribuzioni di radice dei modelli di riferimento dei due regimi, calcolate con il medesimo liscio sull'alfabeto congelato. Questa grandezza quantifica in modo simmetrico e rigoroso la distanza tra due distribuzioni marginali di simboli; è definita come

$$JSD(P, Q) = \frac{1}{2} D(P \parallel M) + \frac{1}{2} D(Q \parallel M), \text{ con } M = \frac{1}{2} (P + Q),$$

dove D è la divergenza di Kullback–Leibler con logaritmi in base 2 [20, 22]; il valore è compreso fra 0, per distribuzioni identiche, e 1 bit, per distribuzioni prive di simboli in comune. Questa lettura, insieme all'ispezione delle frequenze, ha carattere dichiaratamente descrittivo.

6.9 H2: trasferimento fra regimi (lettura predittiva). Per ciascun documento d vengono costruiti due modelli leave-one-document-out: uno sul regime di appartenenza, escludendo d , e uno sull'altro regime. I due pool di addestramento vengono sottocampionati per frasi intere alla taglia comune T (Metodologia 6.6); la procedura viene ripetuta su più semi di sottocampionamento e i punteggi vengono mediati sui semi. L'asimmetria di trasferimento è

$$\Delta CE(d) = CE_{altro}(d) - CE_{proprio}(d).$$

La statistica confermativa è la media di $\Delta CE(d)$ sui documenti. L'ipotesi è che tale media sia positiva: se esistono regolarità specifiche di regime, il modello del regime proprio deve assegnare una lunghezza di codice minore. Con addestramento appaiato, sotto l'ipotesi nulla e sotto l'assunzione di simmetria dei segni (Metodologia 6.6), il test è il sign-flip esatto: l'enumerazione delle $2^{11} = 2048$ configurazioni di segno possibili.

6.10 Statistica secondaria: la profondità selezionata. Per ciascun documento viene calcolata la profondità media del contesto effettivamente utilizzato, sulle stesse posizioni ristrette del guadagno e

sotto lo stesso protocollo cieco alle etichette; le medie dei due regimi sono confrontate mediante la medesima permutazione esatta. È una statistica secondaria perché dipende più direttamente dalla profondità massima, dal supporto minimo e dalla regola di selezione.

6.11 Molteplicità, effetti e incertezza. La procedura di Holm–Bonferroni [17] controlla la famiglia delle due statistiche confermatrice (H1, guadagno di contesto; H2, trasferimento predittivo) ad $\alpha = 0,05$, con soglie ordinate 0,025 e 0,05. I minimi p esatti raggiungibili dal disegno primario ($1/2048 \approx 0,00049$ per il sign-flip, $1/462 \approx 0,0022$ per la permutazione delle etichette) sono inferiori ad entrambe le soglie: la significatività di famiglia è dunque raggiungibile. Gli effetti sono riportati nelle unità naturali delle statistiche, cioè bit per simbolo. Gli intervalli di confidenza sono ottenuti mediante bootstrap documentale stratificato per regime. Data la ridotta numerosità, gli intervalli devono essere interpretati con cautela e accompagnati da visualizzazioni dei singoli documenti. La numerosità ridotta impone infine un controllo della dipendenza autoriale. Poiché il corpus contiene più opere dello stesso autore, l'intera analisi confermatrice viene replicata in forma conservativa trattando come unità non i documenti ma i blocchi autoriali. Per il greco si tratta di tre blocchi esametrici (il poema omerico, il gruppo esiodeo, l'inno anonimo) e tre di prosa (Erodoto, Tucidide, il gruppo delle orazioni di Lisia). Con sei blocchi le enumerazioni esatte contano 20 assegnazioni per la permutazione delle etichette e 64 configurazioni per il sign-flip: i p minimi raggiungibili, rispettivamente 0,10 e circa 0,016, sono dichiarati in anticipo e mostrano che questa replica non può raggiungere la significatività di famiglia. Il suo ruolo non è confermativo: è verificare che il segno e l'ordine di grandezza degli effetti sopravvivano quando la dipendenza fra documenti dello stesso autore viene rimossa per costruzione.

6.12 Validazione dello strumento. Prima dell'analisi dei dati reali, l'implementazione deve superare test su sorgenti sintetiche con risultati analitici noti: una sorgente uniforme indipendente; un ciclo deterministico; una catena di Markov di ordine 1 con tasso noto; un processo di ordine 2 costruito in modo che un modello di ordine 1 non possa raggiungere la cross-entropia ottimale. I test verificano l'ordine predici-poi-aggiorna, la normalizzazione delle probabilità, la selezione della profondità, la corretta gestione dei confini di frase, l'assenza di leakage e l'invarianza dei punteggi del protocollo comune rispetto alla permutazione preventiva delle etichette.

6.13 Congelamento e piano di sensibilità. L'audit del corpus precede l'adattamento di qualunque modello ai dati reali. Dopo l'audit vengono fissati registro dei documenti, alfabeto osservato, politiche di esclusione e taglia comune di T e il numero di semi S (Metodologia 6.6, 6.8); le definizioni delle due statistiche confermatrice, i protocolli e il piano inferenziale vengono quindi congelati prima dei modelli descrittivi. Il piano di sensibilità comprende tredici configurazioni pre-specificate: un blocco fattoriale che incrocia tre politiche di alfabeto (relazioni UD con eliminazione delle residue; relazioni UD con categoria residuale unica; soli UPOS) e due politiche di confine di frase (azzeramento del contesto; simbolo esplicito di confine), più sette variazioni una-alla-volta attorno alla configurazione primaria: tre valori alternativi del lisciamento, due della profondità massima, la regola di selezione alternativa e la rimozione della restrizione di posizione. Le tredici configurazioni non hanno tutte lo stesso ruolo. Le sette variazioni una-alla-volta modificano parametri dello strumento lasciando invariato l'oggetto osservato: su queste, insieme alla configurazione primaria, viene richiesta la stabilità del segno dell'effetto perché una conclusione sostanziale possa essere formulata; un'instabilità entro questo blocco sarebbe essa stessa un risultato, e come tale verrebbe riportata. Le celle del blocco fattoriale che modificano la politica di alfabeto o di confine cambiano invece la rappresentazione osservata: eliminare le relazioni di dipendenza, o introdurre un simbolo esplicito di confine, non è una perturbazione numerica ma una scelta su quale informazione osservare. I loro esiti vengono perciò riportati e interpretati, non usati come condizione di validità: un effetto presente con l'alfabeto completo e assente con i soli UPOS, per esempio, localizzerebbe la firma nell'informazione di dipendenza, e costituirebbe un risultato interpretabile, non un difetto di robustezza. Ogni conclusione primaria resta riferita, esplicitamente, alla rappresentazione primaria.

6.14 H3: replica latina e controllo della taglia. Il latino utilizza lo stesso strumento e gli stessi protocolli, adattati alla propria numerosità. Il sign-flip dispone di $2^8 = 256$ configurazioni e la permutazione delle etichette di 28 assegnazioni. Dato il ridotto volume a disposizione i risultati non possono che essere qualitativi, non entrano nella famiglia di Holm, e l'ipotesi di replica è per disegno subordinata ai risultati greci. Per distinguere le differenze linguistiche dagli effetti di campione, un numero predefinito di sottocampioni greci dovrà essere portato alla dimensione del latino, e i valori latini saranno localizzati rispetto alla distribuzione ottenuta da tali sottocampioni.

7. ASPETTI COMPUTAZIONALI

7.1 Pipeline. La pipeline sarà implementata in Python 3.12 mediante librerie standard per il trattamento dei dati, il calcolo numerico, l'inferenza e la visualizzazione. I file CoNLL-U verranno acquisiti, validati e trasformati in registri documentali; la funzione di mapping dell'alfabeto produrrà per ogni token mantenuto un simbolo. Le sequenze, i modelli, i punteggi per documento e le figure saranno salvati in formati aperti e accompagnati da metadati.

7.2 Riproducibilità. Ogni risultato dovrà essere ricostruibile dalla versione dei dati, dalla configurazione, dal commit del codice e dal seme casuale. Le dipendenze software verranno congelate; i dati grezzi resteranno immutabili e nessun file derivato sarà sovrascritto senza autorizzazione. I test automatici copriranno sia la pipeline sia le identità matematiche dello strumento. La disponibilità pubblica del codice e delle configurazioni consentirà di replicare l'analisi senza ridistribuire i treebank.

7.3 Risorse. Il modello non richiede GPU o infrastrutture specialistiche. La complessità è compatibile con un comune computer portatile; il costo complessivo deriva soprattutto dalla ripetizione dei fit nei protocolli leave-one-out e nel piano di sensibilità. La fattibilità temporale verrà verificata mediante profilazione su dati sintetici prima dell'analisi reale.

7.4 Piano di lavoro. Le fasi previste sono: predisposizione dell'ambiente e dei test di base; acquisizione e audit del corpus; congelamento del piano confermativo; implementazione e validazione del context tree; costruzione dei modelli di riferimento; calcolo delle statistiche confermativie; replica latina; analisi di sensibilità; interpretazione linguistica dei contesti e infine scrittura.

8. POTENZIALI LIMITI

8.1 Dimensione e granularità del corpus. Il contrasto greco primario comprende undici documenti e un numero ancora minore di autori indipendenti. La potenza è quindi limitata e la dipendenza intra-autore non può essere completamente eliminata. La replica conservativa a livello di autore (Metodologia 6.11) si muove in questa direzione e verifica inoltre se il segno e l'ordine di grandezza degli effetti persistano quando l'unità di analisi viene elevata al blocco autoriale.

8.2 Confondenti filologici e storici. Metro, genere, epoca, dialetto, autore e tradizione testuale non sono ortogonali. L'esametro greco primario è in larga parte arcaico e ionico-epico, mentre la prosa è ionica o attica e cronologicamente successiva. Nel latino, epica, storiografia, oratoria, biografia e romanzo sono rappresentati in modo diseguale. Il disegno nomina questi confondenti, utilizza tragedia e prosa post-classica come controlli esplorativi e vieta l'attribuzione causale diretta al metro.

8.3 Limiti della rappresentazione. UPOS+DEPREL è una proiezione con perdita. Non rappresenta l'albero completo, la distanza delle dipendenze, l'ordine relativo fra head e dipendente come tratto esplicito, le feature morfologiche, il lemma o la semantica. Un risultato nullo può indicare assenza di differenze al livello osservato ma non implicherebbe necessariamente l'assenza di differenze linguistiche. Un risultato positivo riguarda la rappresentazione adottata e non autorizza affermazioni sulla complessità sintattica complessiva.

8.4 Qualità e convenzioni dell'annotazione. I treebank combinano annotazione manuale, strumenti automatici e conversioni fra schemi. L'ordine non canonico della poesia può rendere più difficile

l'assegnazione delle dipendenze; alcune convenzioni variano fra treebank e lingue [14, 15]. Audit per documento, controllo solo-UPOS, politiche di esclusione e analisi di sensibilità riducono il rischio, ma non lo eliminano.

8.5 Misspecificazione del modello. Il *context tree* è lineare e a memoria finita. Non rappresenta ricorsione, gerarchia o dipendenze non locali in quanto tali. L'obiezione di Chomsky [16] impedisce di interpretarlo come grammatica o modello generativo della lingua. Il progetto utilizza il modello come strumento comparativo di codifica; se la firma dipende da proprietà non accessibili alla proiezione lineare, lo strumento potrebbe non rilevarla.

8.6 Confini di frase e di verso. La segmentazione in frasi è in parte editoriale e può differire fra regimi. L'azzeramento del contesto a inizio frase viene controllato attraverso la restrizione di posizione e la sensibilità con simbolo di confine. I confini di verso, direttamente pertinenti al vincolo metrico, non sono disponibili nel formato utilizzato; la loro assenza limita l'interpretazione e impedisce di localizzare gli effetti rispetto alla struttura del verso.

8.7 Limiti del latino. Il corpus latino è piccolo, eterogeneo e dispone di due soli documenti esametrici. L'assenza dell'articolo, la diversa distribuzione delle particelle e le differenze annotative rendono improprio un confronto numerico diretto con il greco. La replica latina resta quindi qualitativa e viene letta rispetto a sottocampioni greci della stessa taglia.

8.8 Portata delle conclusioni. Il progetto è uno studio di caso su specifici treebank e specifiche tradizioni. Non generalizza automaticamente ad altre lingue, altri metri o alla poesia in generale. Non identifica una legge universale dei vincoli formali e non definisce una teoria statistica della lingua poetica. Verifica se un particolare livello di rappresentazione e un particolare strumento rivelino una differenza riproducibile nel corpus considerato.

9. RISULTATI ATTESI

9.1 Obiettivo principale. Il risultato principale è la localizzazione dell'eventuale firma dell'esametro. Una differenza limitata alla radice indicherebbe soprattutto un diverso repertorio o una diversa frequenza delle categorie morfosintattiche. Una differenza nel guadagno di contesto (H1) indicherebbe che il contesto lineare acquista un valore informativo diverso nei due regimi. Una differenza nel trasferimento predittivo (H2) indicherebbe che le regolarità predittive entro regime trasferiscono meno efficacemente all'altro regime. Le grandezze saranno espresse in bit per simbolo e accompagnate da intervalli e punteggi per documento.

9.2 Interpretazione degli esiti. Tutti gli esiti sono informativi. Un esito positivo su entrambe le ipotesi individuerrebbe una firma sia diversa per quantità di informazione contestuale (H1) sia specifica di regime (H2). Un esito positivo soltanto su H2 suggerirebbe regolarità predittive differenti ma con guadagno medio simile; un esito positivo soltanto su H1 suggerirebbe una diversa dipendenza dal contesto senza forte asimmetria di trasferimento. Una differenza esclusivamente distribuzionale confinerrebbe l'effetto alla radice. Un esito nullo generale, dopo validazione e sensibilità, indicherebbe che la proiezione UPOS+DEPREL e il *context tree* non distinguono stabilmente i regimi in questo corpus.

9.3 Disciplina delle affermazioni. La formulazione ammessa sarà: «in questo corpus, il regime esametrico differisce dalla prosa classica nella lettura X per un effetto di Y bit per simbolo, con il relativo intervallo di confidenza». Non verrà affermato che il metro causa la differenza, che la poesia possiede una grammatica distinta o che la profondità del *context tree* coincide con profondità sintattica o memoria cognitiva. I contesti selezionati saranno descritti come sequenze lineari di etichette morfosintattiche e ricondotti alle frasi originali prima di qualunque interpretazione linguistica.

9.4 Uscite previste. Le uscite comprenderanno: registro del corpus e audit dell'alfabeto; distribuzioni di radice e divergenza di Jensen–Shannon fra i regimi, con i contributi per simbolo; matrice delle cross-entropie; valori individuali e medi dell'asimmetria di trasferimento ΔCE e del guadagno di contesto G ; profili del guadagno rispetto al contesto disponibile; distribuzioni delle profondità; curve di apprendimento; stabilità nelle configurazioni di sensibilità; un lessico descrittivo dei contesti che producono il maggiore risparmio di codice. La lettura dei contesti avrà funzione interpretativa e non confermativa.

10. PROSPETTIVE FUTURE

10.1 Confini di verso e rappresentazioni più ricche. Una prima estensione consiste nel riallineare i treebank alle edizioni metriche per reintrodurre i confini di verso e verificare se gli effetti si concentrino in specifiche posizioni dell'esametro. Rappresentazioni che conservino direzione, distanza o configurazioni di dipendenza potrebbero essere confrontate con la proiezione attuale, ma costituirebbero un ampliamento distinto del progetto e richiederebbero nuove ipotesi e nuovi controlli.

10.2 Robustezza del modello. Il Context-Tree Weighting [12] può essere utilizzato come comparatore per stabilire se le conclusioni dipendano dalla regola di selezione MDL. Ulteriori metodi di codifica universale potrebbero essere introdotti soltanto come repliche metodologiche, evitando di ricostruire una batteria di misure eterogenee.

10.3 Ampliamento dei corpora. Un corpus latino più ampio consentirebbe un confronto per periodo e genere. L'introduzione di altri metri, della tragedia in forma più controllata o di tradizioni poetiche differenti permetterebbe di distinguere una firma dell'esametro da una firma più generale del verso.

10.4 Vincoli formali e sorgenti simboliche. Qualora il metodo mostri stabilità, potrà essere impiegato per confrontare altri regimi linguistici sottoposti a vincolo. Il contributo potenziale rimane metodologico: fornire una procedura per localizzare dove una distinzione qualitativa si manifesta nell'organizzazione predittiva di una sequenza simbolica. Qualunque estensione oltre la linguistica dovrà essere verificata caso per caso.

11. IL RUOLO DEL SUPERVISORE

11.1 Supervisione matematico-computazionale. La supervisione matematico-computazionale è necessaria per verificare la formulazione del context tree, la corretta implementazione prequenziale, la selezione MDL, i protocolli held-out e la validità dell'inferenza esatta. La supervisione comprenderà inoltre la valutazione della coerenza fra statistiche, ipotesi e interpretazione delle lunghezze di codice.

11.2 Supervisione linguistica. La supervisione linguistica è necessaria per verificare il corretto uso di Universal Dependencies, la composizione dei regimi, le scelte dell'alfabeto e l'interpretazione dei contesti selezionati. Il contributo della supervisione linguistica sarà circoscritto alla verifica della correttezza della rappresentazione adottata, dei limiti della proiezione e della corrispondenza fra risultati statistici e livello linguistico effettivamente osservato.

11.3 Supervisione filologica. La competenza filologica, eventualmente integrata nella supervisione linguistica, è utile per controllare l'attribuzione dei testi, la classificazione metrica, la comparabilità cronologica e di genere e le peculiarità della lingua poetica greca e latina. Questi controlli sono essenziali per distinguere i risultati dello strumento dai problemi di corpus.

BIBLIOGRAFIA

- [1] C. E. Shannon (1948). «A Mathematical Theory of Communication». Bell System Technical Journal 27(3): 379–423; 27(4): 623–656.

- [2] M.-C. de Marneffe, C. D. Manning, J. Nivre, D. Zeman (2021). «Universal Dependencies». *Computational Linguistics* 47(2): 255–308.
- [3] P. W. Anderson (1972). «More Is Different». *Science* 177(4047): 393–396.
- [4] T. Schürmann, P. Grassberger (1996). «Entropy estimation of symbol sequences». *Chaos* 6(3): 414–427; arXiv:cond-mat/0203436.
- [5] M. A. Montemurro, D. H. Zanette (2011). «Universal Entropy of Word Ordering Across Linguistic Families». *PLoS ONE* 6(5): e19875.
- [6] R. Mansilla, E. Bush (2003). «Increase of Complexity from Classical Greek to Latin Poetry». *Complex Systems* 14(3): 201–213.
- [7] A. Šeĭa, M. Gronas (2022). «Measuring Rhythm Regularity in Verse: Entropy of Inter-Stress Intervals». In *CHR 2022: Computational Humanities Research Conference, CEUR Workshop Proceedings Vol-3290*, Anversa, pp. 231–242.
- [8] J. Rissanen (1983). «A universal data compression system». *IEEE Transactions on Information Theory* 29(5): 656–664.
- [9] P. Bühlmann, A. J. Wyner (1999). «Variable length Markov chains». *Annals of Statistics* 27(2): 480–513.
- [10] I. Csizsár, Z. Talata (2006). «Context tree estimation for not necessarily finite memory processes, via BIC and MDL». *IEEE Transactions on Information Theory* 52(3): 1007–1016.
- [11] A. Galves, C. Galves, J. E. García, N. L. Garcia, F. Leonardi (2012). «Context tree selection and linguistic rhythm retrieval from written texts». *Annals of Applied Statistics* 6(1): 186–209.
- [12] F. M. J. Willems, Y. M. Shtarkov, T. J. Tjalkens (1995). «The Context-Tree Weighting Method: Basic Properties». *IEEE Transactions on Information Theory* 41(3): 653–664.
- [13] D. Bamman, G. Crane (2011). «The Ancient Greek and Latin Dependency Treebanks». In C. Sporleder, A. van den Bosch, K. Zervanou (a cura di), *Language Technology for Cultural Heritage*, Springer, Berlino–Heidelberg, pp. 79–98.
- [14] S. L. Chen, P. J. Burns, T. J. Bolt, P. Chaudhuri, J. P. Dexter (2024). «Leveraging Part-of-Speech Tagging for Enhanced Stylometry of Latin Literature». In *Proceedings of the 1st Workshop on Machine Learning for Ancient Languages (ML4AL 2024)*, ACL, pp. 251–259.
- [15] S. Herrera, I.-M. Silai, B. Guillaume, S. Kahane (2025). «Extraction of Contrastive Rules from Syntactic Treebanks: A Case Study in Romance Languages». In *Proceedings of the Third Workshop on Quantitative Syntax (QUASY, SyntaxFest 2025)*, ACL, pp. 26–38.
- [16] N. Chomsky (1956). «Three Models for the Description of Language». *IRE Transactions on Information Theory* IT-2(3): 113–124.
- [17] S. Holm (1979). «A simple sequentially rejective multiple test procedure». *Scandinavian Journal of Statistics* 6(2): 65–70.
- [18] Universal Dependencies, treebank UD_Ancient_Greek-Perseus (grc_perseus), release v2.18 — 13.919 frasi, 202.989 token; conversione UD di G. G. A. Celano da AGLDT 2.1; licenza CC BY-NC-SA 2.5. https://universaldependencies.org/treebanks/grc_perseus/
- [19] Universal Dependencies, treebank UD_Latin-Perseus (la_perseus), release v2.18 — 2.273 frasi, 28.868 token / 29.223 parole sintattiche, 355 multiword token; stessa provenienza e licenza. https://universaldependencies.org/treebanks/la_perseus/
- [20] T. M. Cover, J. A. Thomas (2006). *Elements of Information Theory*, seconda edizione, Wiley-Interscience.
- [21] M. Greco, A. Cometa, F. Artoni, R. Frank, A. Moro (2023). «False perspectives on human language: Why statistics needs linguistics». *Frontiers in Language Sciences* 2: 1178932.
- [22] J. Lin (1991). «Divergence measures based on the Shannon entropy». *IEEE Transactions on Information Theory* 37(1): 145–151.